Metis 推理：逐候选打分，再按分数返回 ID

同一 query 的候选保持顺序；每个微批复用同一基座和评分头。

$b \le 4,\quad L \le 2048,\quad D = 1024,\quad h = 256$

1. 候选微批：输入、主干与末尾读出

eval() + no_grad()；参数不更新

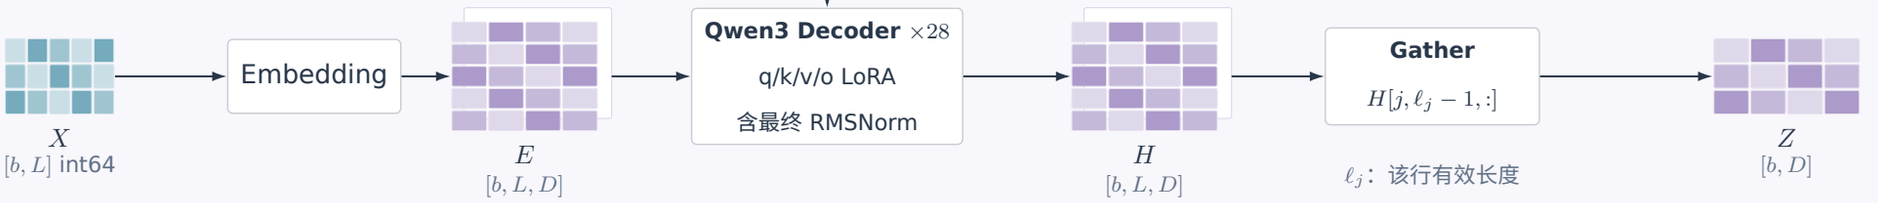
$M : [b, L]\quad P : [b, L]$

M: padding 支持；P: 逻辑位置

每行一个候选序列

叠层 b；面 $L \times D$

末尾有效后缀位置

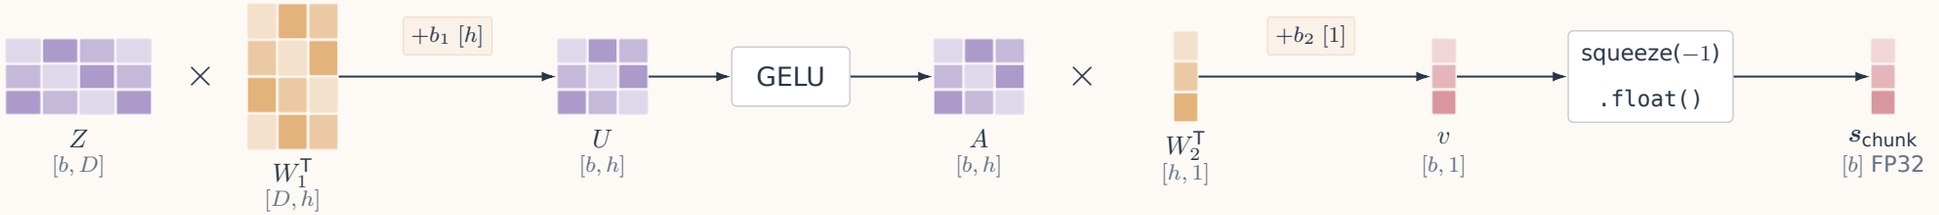


ℓ_j：该行有效长度

M, P 为 int64；M 不是完整因果矩阵。注意力：$Q : [b, 16, L, 128]$，$K, V : [b, 8, L, 128]$。

2. 独立评分头：$D \to h \to 1$

左侧 Z 承接上行；s_{chunk} 供下行合并微批



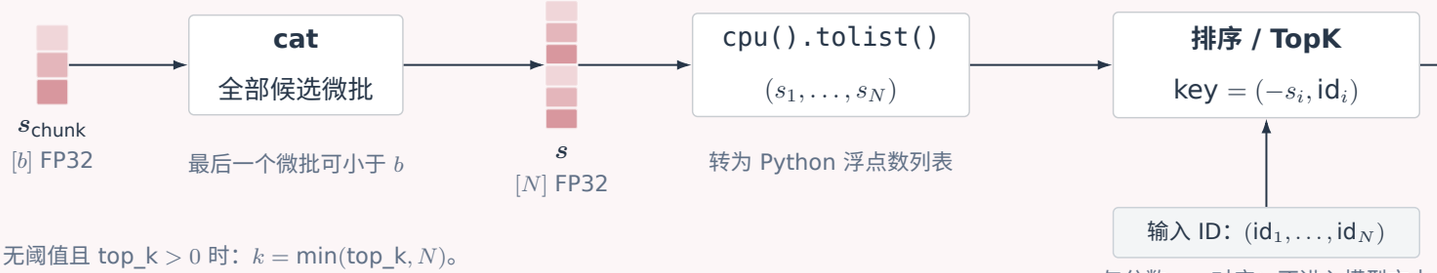
实际存储：$W_1 : [h, D]$、$W_2 : [1, h]$；图中矩乘展示转置。b_1, b_2 沿候选行广播。

3. 排序任务：合并全量分数，再做 TopK

承接上方同名输出

N：全部候选数

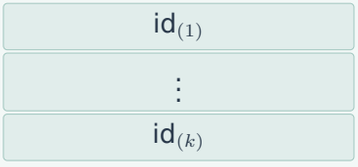
分数降序，同分按 ID



无阈值且 top_k > 0 时：$k = \min(\text{top_k}, N)$。

同名张量为同一结果的引用；跨微批 cat 保留原候选顺序。

4. 返回字符串 ID



selected_ids

字符串列表，长度 k

调用方可按 ID 查原文

Predictor 不返回原文列表

输入 / 二值支持　隐藏激活　可训练参数　分数 / 损失　位置 / 标签 / ID　选中 ID

实线：前向 / 数据流　　红色虚线：梯度，方向与前向相反（仅训练）

推理不构建计算图、无梯度、无 KV cache；use_cache=False。色格数量和深浅仅示意，不表示实际维数或实测值。