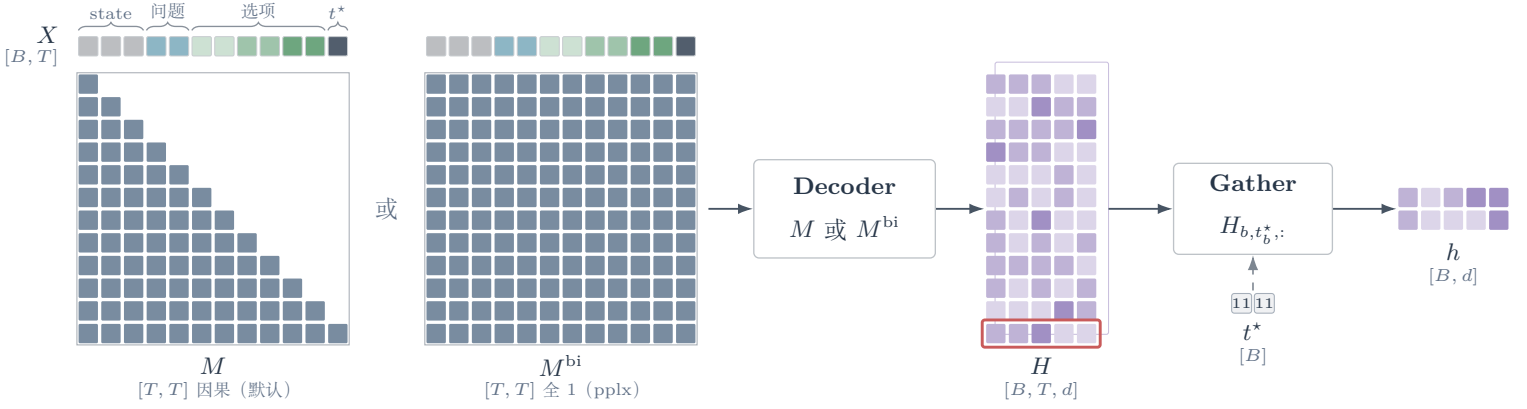
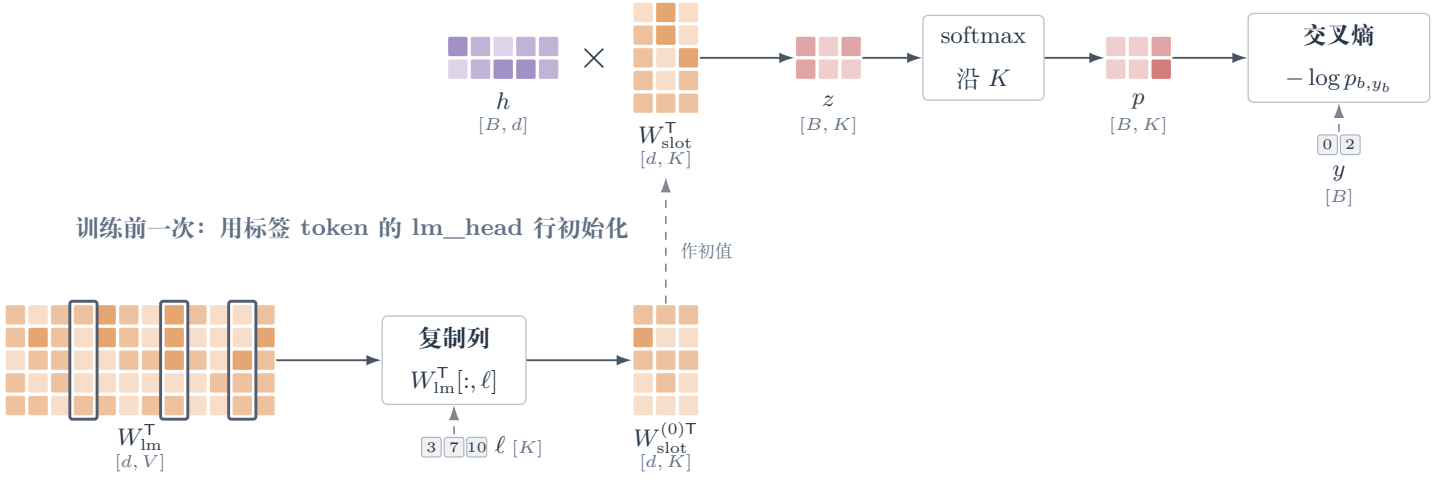
$$W_{\text{slot}}^{(0)} = W_{\text{lm}}[\ell, :], \quad z_b = W_{\text{slot}}\, h_b, \quad p_b = \text{softmax}_k(z_b), \quad \mathcal{L} = -\tfrac{1}{B}\sum_b \log p_{b,y_b}$$

输入与读出 1 相同；mask 默认因果，pplx 把全注意力层改为非因果



独立可训练头 $\text{Linear}(d, K)$：每个槽位一行，沿 K 归一化



轴	B 问题数；T 序列长度；d hidden；V 词表；K 槽位数 = 可表达的选项上限（pplx 与 d3 为 255，AutoTrust 264）。
对象	W_{slot} 独立可训练权重，存储 $[K, d]$，图中转置；$W_{\text{slot}}^{(0)}$ 其初值；ℓ 槽位对应 token 的词表 id；M 因果、M^{bi} 全 1 的可见性；z logits，p 槽位上的概率。
机制	与读出 1 共用输入和 gather，只把 “读 V 列再挑 L 列” 换成可训练的 K 行；导出时可把 W_{slot} 写回 lm_head 的 ℓ 行供普通引擎服务。改用 M^{bi} 后，普通 CausalLM 推理不再等价。