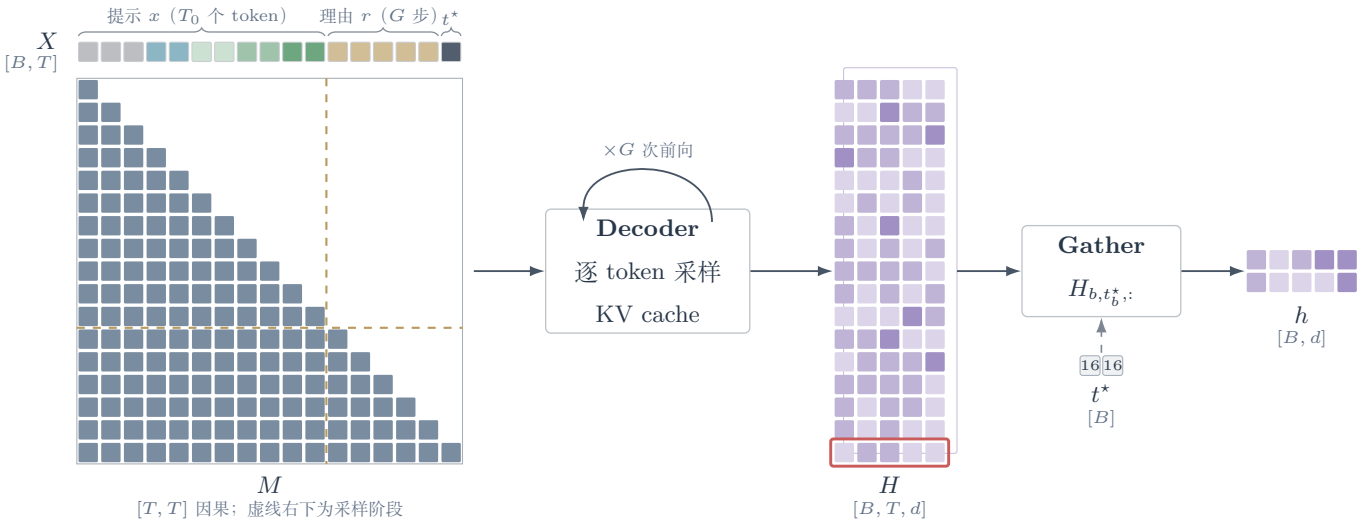
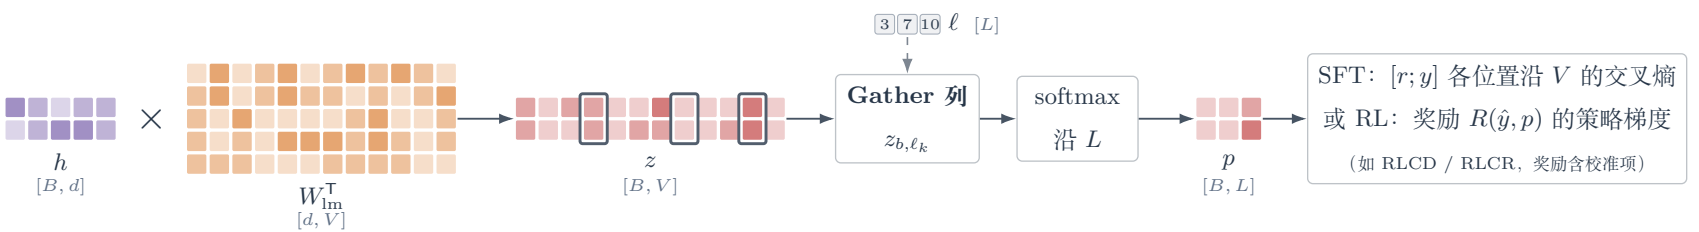
$$r_{1:G} \sim \pi_\theta(\cdot \mid x), \quad h_b = H_{b,t^\star_b,:}\ (\text{在}[x;r]\ \text{上}), \quad z_b = W_{\text{lm}} h_b, \quad p_b = \text{softmax}_k(z_{b,\ell_k})$$

先自回归采样理由（G 次前向），再在末位置按读出 1 读标签分布



读出与读出 1 相同；训练目标覆盖理由 token 或改用强化学习



轴	B 问题数；T_0 提示长度；G 采样的理由长度；$T = T_0 + G + 1$；d hidden；V 词表；L 标签 token 数。
对象	r 采样得到的理由 token（随机变量，非确定输入）；$t^\star$ 理由之后答案提示的末位置；ℓ 标签 token id；$\hat{y}$ 采样或 argmax 得到的答案；R 奖励。
机制	每问题 $1+G$ 次前向，延迟随 G 线性增长，且结果受采样随机性影响；与 System One “一次前向出判断” 的定位冲突，MetisCraft 只作对照或可选兜底。