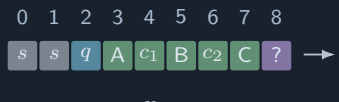
$$h = H_{t^\star,:}, \quad s_k = \langle W_{\ell_k,:}, h \rangle, \quad p = \mathrm{softmax}_K(s/\tau)$$

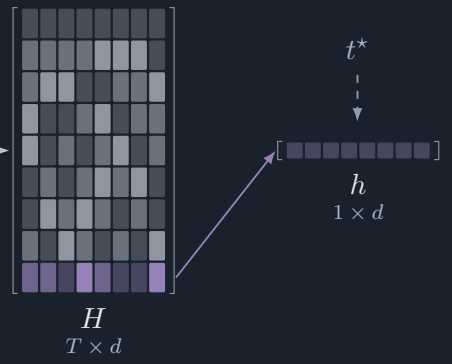
1. Token 组织



2. jebadiah

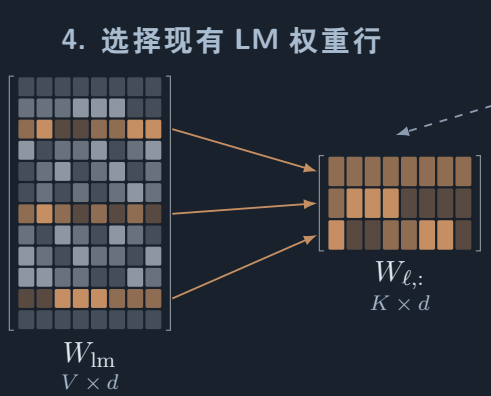
32 层因果混合主干
Qwen3.5-4B
LoRA r=16；末层 RMSNorm

3. 上下文状态与读出索引

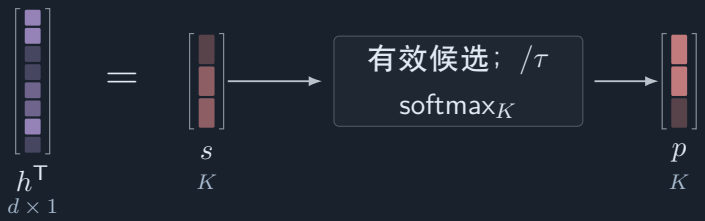


$d = 2560,\ V = 248320$

4. 选择现有 LM 权重行



5. FP32 部分行投影



不新增标量头
推理不产生完整 V logits

轴	$d = 2560,\ V = 248320$; 展示单题并省略 batch；格数表示轴结构，不是真实大小。
对象	灰色：输入 / 上下文；紫色：隐状态；橙色：参数矩阵；红色：logits / 概率。位置、答案码和 owner 为整数索引，不是分数。色块表示角色，不表示实测大小。
机制	所有选项共享一条因果提示，在下一个答案位置读出。端点候选上限及是否应用温度属于另一层服务契约。候选空间硬 / 软目标 CE，无 EOS completion 目标。所查评分器先选原始 LM 行，再做 FP32 乘法。