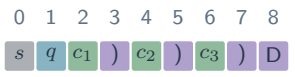
$$E = H[P_{opt}, :],\ D = H[P_{decide}, :], \quad k = EW_k^{\mathsf{T}} + b_k,\ q = DW_q^{\mathsf{T}} + b_q, \quad s = kq^{\mathsf{T}}/\sqrt{d_p}$$

1. Token 组织

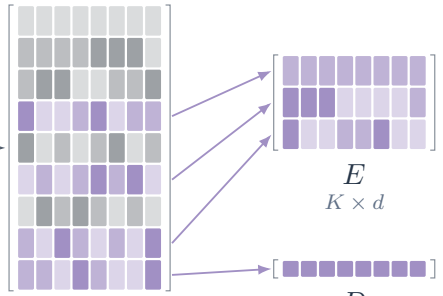


x
T 个整数 token ID

2. Kev

32 层因果混合主干
Qwen3.5-4B-Base；
LoRA r=16
每道题单独一行

3. 上下文状态与读出索引



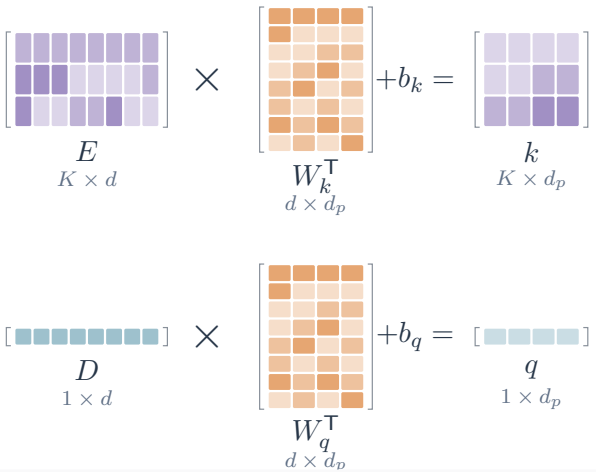
H
$T \times d$

E
$K \times d$

D
$1 \times d$

E：候选闭合位置
D：decision 标记
decision 可见全部选项

4. 两个独立带偏置投影



E
$K \times d$

W_k^{T}
$d \times d_p$

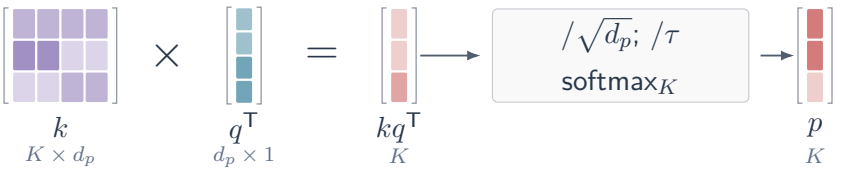
k
$K \times d_p$

D
$1 \times d$

W_q^{T}
$d \times d_p$

q
$1 \times d_p$

5. Query 与候选的点积



k
$K \times d_p$

q^{T}
$d_p \times 1$

kq^{T}
K

p
K

轴	$d = 2560,\ d_p = 256$; 展示单题并省略 batch；格数表示轴结构，不是真实大小。
对象	灰色：输入 / 上下文；紫色：隐状态；橙色：参数矩阵；红色：logits / 概率。位置、答案码和 owner 为整数索引，不是分数。色块表示角色，不表示实测大小。
机制	混合 Kev-4B 采用逐题行，不执行 packed mask 路径。候选闭合位置因果可见，decision query 读取全部选项；未读取头文件内实际温度。 固定权重配置采用候选 CE；两个带偏置的 d→256 投影。pointer 的 sqrt(256) 缩放与拟合温度是不同运算。