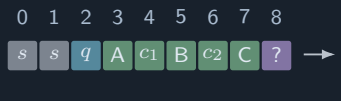
$$h = H_{t^\star,:}, \quad s_k = \langle W_{\ell_k,:}, h \rangle, \quad p = \mathrm{softmax}_K(s/\tau)$$

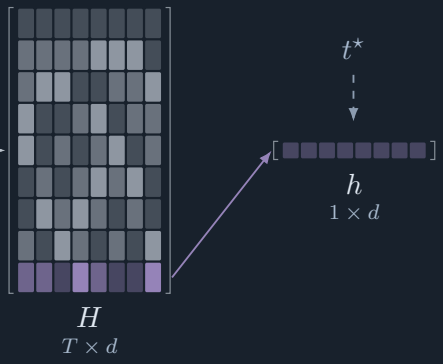
1. Token 组织



2. mammoth-1



3. 上下文状态与读出索引





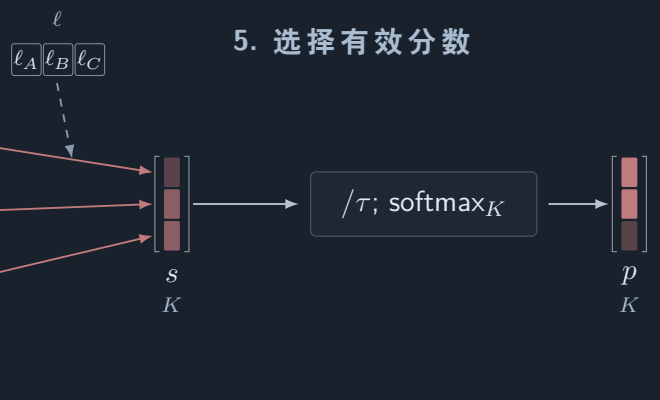
4. 已存头参数的投影







5. 选择有效分数



沿用原始 LM 词表头

轴	$d = 5120$, $V = 248320$; 展示单题并省略 batch；格数表示轴结构，不是真实大小。
对象	灰色：输入 / 上下文；紫色：隐状态；橙色：参数矩阵；红色：logits / 概率。位置、答案码和 owner 为整数索引，不是分数。色块表示角色，不表示实测大小。
机制	共享前缀、独立后缀行与缓存分叉；可选 pointer 的 head_dim=256 不是发布 slot_lm 模型中的 5120→256 MLP。沿用 LM 头后按槽 ID gather，声明 256 槽；源码目标为候选 CE 加槽内求和 Brier，再取 batch 均值。实际训练设置为作者报告。