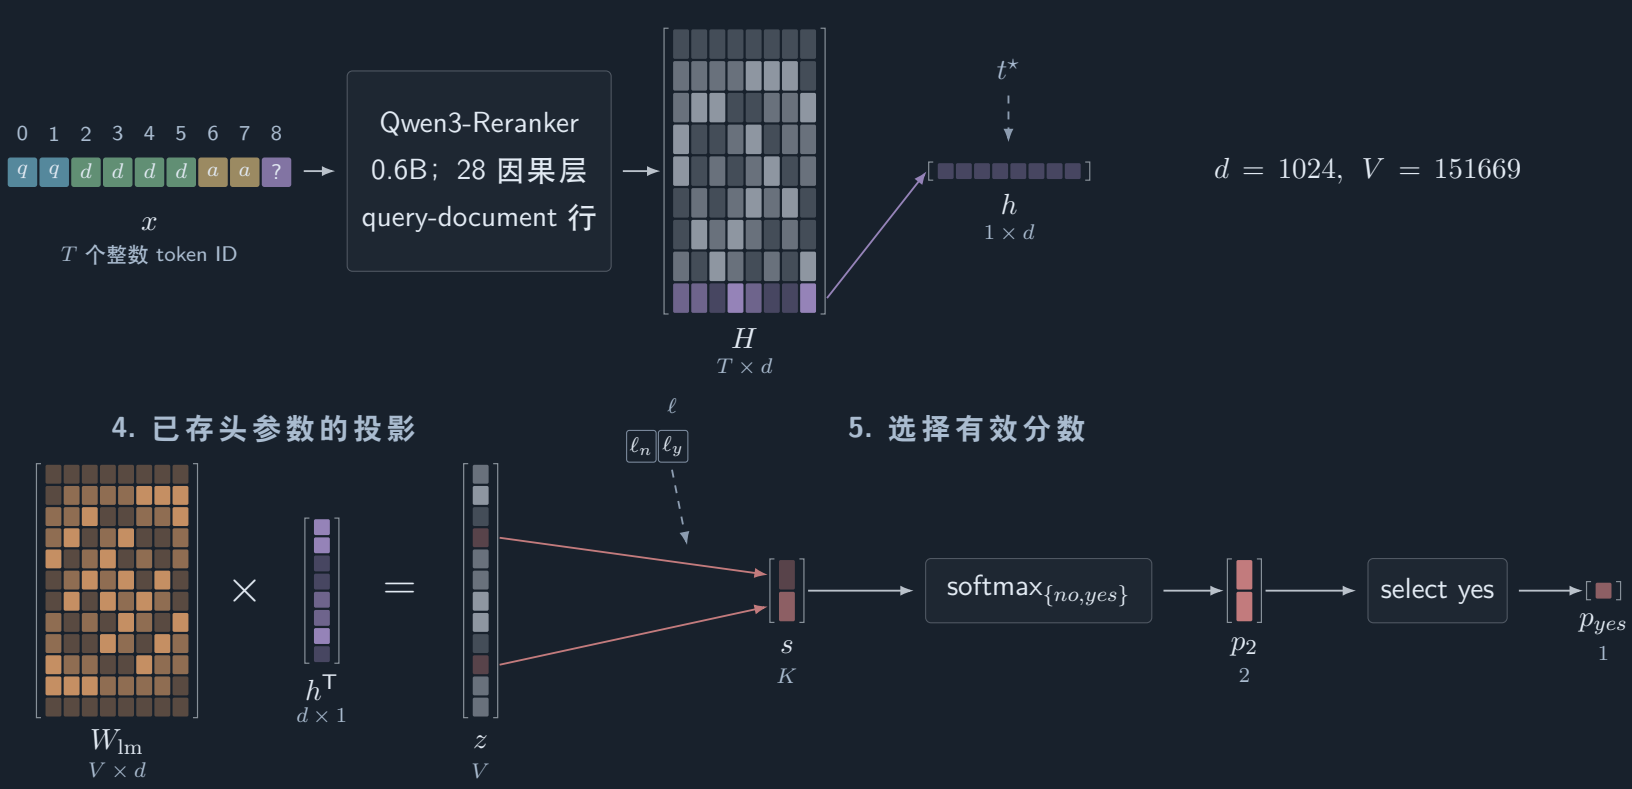
$$z = W_{\mathrm{lm}} h^{\mathsf{T}}, \quad p_{yes} = \mathrm{softmax}(z_{no}, z_{yes})_{yes} = \sigma(z_{yes} - z_{no})$$



轴	$d = 1024$, $V = 151669$; 展示单题并省略 batch；格数表示轴结构，不是真实大小。
对象	灰色：输入 / 上下文；紫色：隐状态；橙色：参数矩阵；红色：logits / 概率。位置、答案码和 owner 为整数索引，不是分数。色块表示角色，不表示实测大小。
机制	P(yes) 是逐对相关分，不在 document 轴 softmax。Q 宽 16×128=2048，K / V 各宽 8×128=1024；hidden 宽不等于拼头宽。索引格中 n=no、y=yes。 官方 Transformers 推理先算词表 logits、取 no / yes 后二列归一化；不能据此推断训练 token mask 或 EOS 目标。