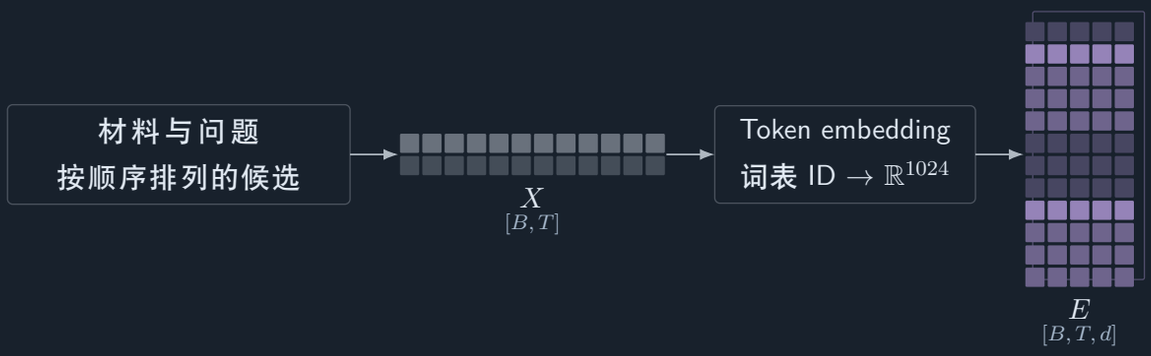
$$X \xrightarrow{\text{Qwen3 decoder}} H \xrightarrow{P\text{ gather}} h \xrightarrow{1024\to256\to1} S \xrightarrow{\tau,\text{ normalize}} p$$

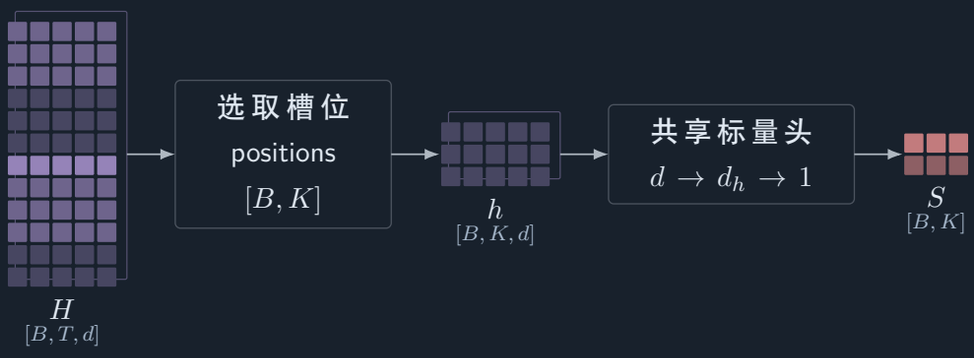
### 1. 一个问题组织为一条候选列表序列



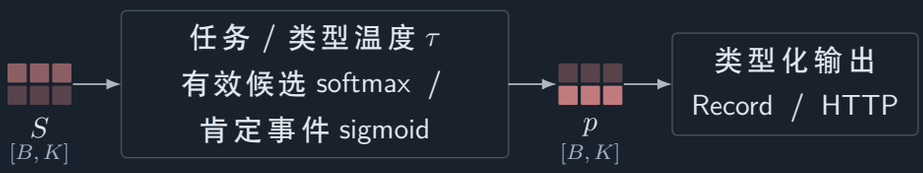

### 2. Qwen3-0.6B-Base 主干；适配线性层使用 LoRA r=16




### 3. 选择候选末端表示；不经过词表输出头




### 4. 校准分数；按问题类型归一化




| | |
|---|---|
| **轴** | $B$：问题数（队列与紧急程度各占一行）；$T$：填充后 token 数；$d = 1024$：隐藏维度；$K$：补齐的候选槽位。队列使用 6 个槽位，紧急程度使用 1 个。 |
| **机制** | 一个可核查的 JevLike 实现：Banking77 客服配方采用共享 $1024 \to 256 \to 1$ 标量 MLP。list 布局中后面的候选可看见前面的候选。本图不推断 Jev 内部结构，也不等同于 Tev1 的答案 token 架构。 |

格子数示意轴结构，而非模型规模；色阶区分语义角色，不表示数值。