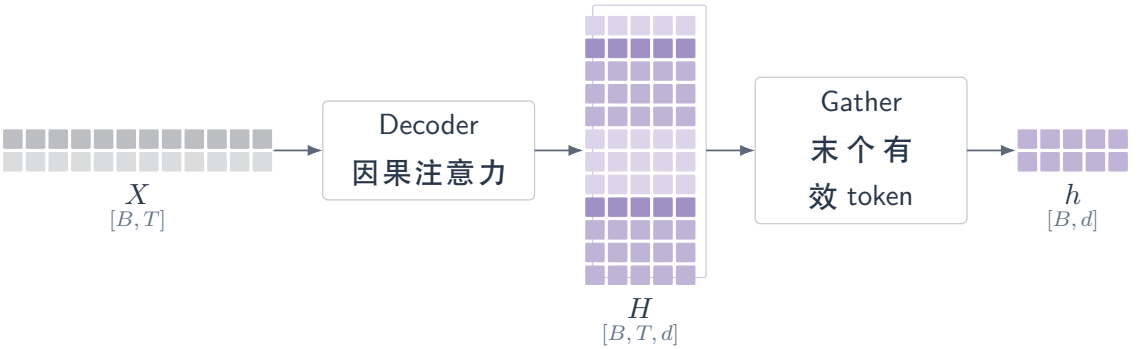
$$h_b = H_{b,t^\star_b,:}, \quad z = hW_{\text{lm}}^{\mathsf{T}}, \quad S_{b,k} = z_{b,\ell_{b,k}}, \quad p_b = \text{softmax}_k(S_b/\tau)$$

因果编码与末位置选择



词表投影，再按顺序选择答案 token



轴	B：问题数；T：token 数；d：隐藏维度；V：词表；L：答案 token 数。W_{lm} 按 $[V, d]$ 存储。
机制	读出位置能看见前面的全部候选。choice 与 score 在所选答案 token 上归一化，而非整个词表；noul 使用 $z_{yes} - z_{no}$ 再做 sigmoid。

格子数示意轴结构，而非模型规模；色阶区分语义角色，不表示数值。