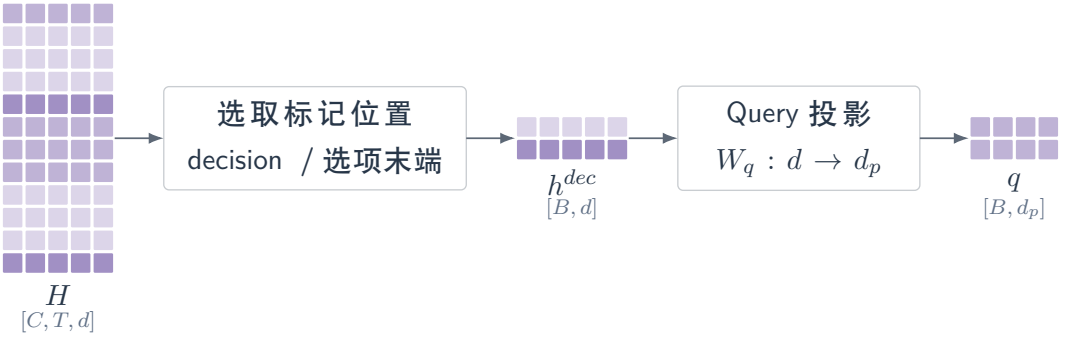
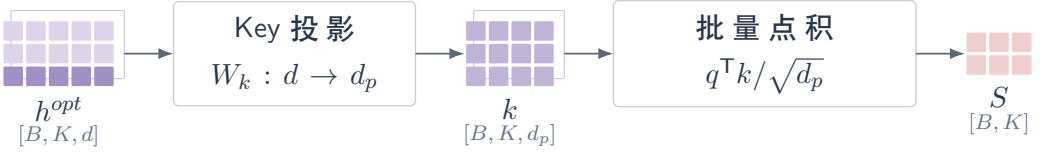
$$q = W_q h^{dec}, \quad k_j = W_k h_j^{opt}, \quad S_{b,j} = \frac{q_b^\top k_{b,j}}{\sqrt{d_p}}, \quad p = \mathrm{softmax}_j(S/\tau)$$

从打包输入中选取各问题的 decision 表示



投影候选表示，与 decision query 计算分数



轴	C：输入序列数；Q：每序列问题数；等长示例中 $B = CQ$。$h^{dec} : [B, d]$；$h^{opt} : [B, K, d]$；d_p：pointer 维度。
机制	这是对照架构，并非 MetisCraft 已实现读出。分支可见性、候选隔离与 position ID 属于打包协议；单序列多问题不意味着普遍提速，混合主干可能需要改用独立行。

格子数示意轴结构，而非模型规模；色阶区分语义角色，不表示数值。