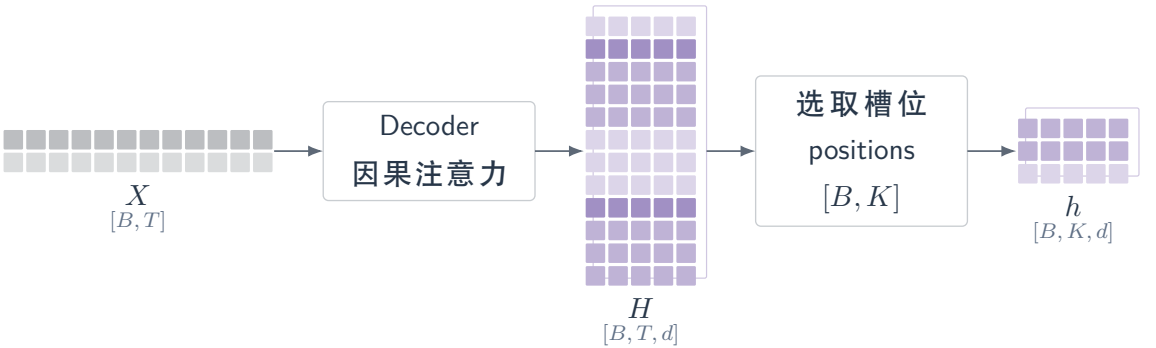
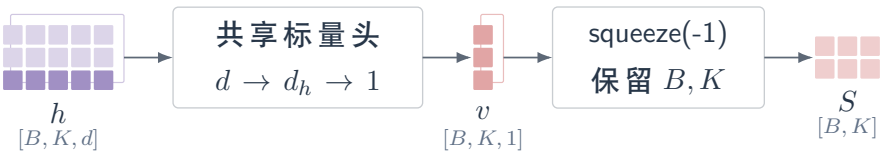
$$h_{b,k} = H_{b,P_{b,k},:}, \quad u = \mathrm{GELU}(hW_1^\mathsf{T} + b_1), \quad S = \mathrm{squeeze}(uW_2^\mathsf{T} + b_2)$$

默认标量布局：候选共享同一条因果序列



选取候选槽位；各槽位使用同一个标量头



轴	$P_{b,k} \in \{0, \ldots, T-1\}$ 是左填充后的候选槽位索引。$h_{b,k} = H_{b,P_{b,k},:}$ 的形状为 $[d]$。
机制	因果 mask 允许后面的候选关注前面的候选。输出使用独立 sigmoid，并不意味着隐藏表示互相独立。list 是当前默认布局；未实现 tree 打包。

格子数示意轴结构，而非模型规模；色阶区分语义角色，不表示数值。